

Projet statistiques bayésiennes

Garance MALNOË et Matthias MAZET

2026-01-29

Contents

1	Introduction	2
2	Simulations du processus	2
2.1	<i>Variations de α</i>	3
2.2	<i>Variations de β</i>	4
2.3	<i>Variations de θ</i>	6
3	Étude de l'inférence bayésienne	7
3.1	<i>Contexte</i>	7
3.1.1	Calcul de la loi a posteriori pour θ	8
3.1.2	Calcul des lois a posteriori pour α	8
3.1.3	Calcul des lois a posteriori pour β	9
3.1.4	Remarque	9
3.2	<i>Fonctions</i>	10
3.2.1	Lois a posteriori	10
3.2.2	Algorithme de Gibbs-Metropolis-Hastings (GMH)	10
3.2.3	Estimateurs du maximum de vraisemblance (MLE) par optimisation	12
3.2.4	Fonction de visualisation	13
3.3	<i>Résultats</i>	14
3.3.1	$\beta < 1$, cas concave	14
3.3.2	$\beta = 1$, cas linéaire	16
3.3.3	$\beta > 1$, cas convexe	18
4	Conclusion	20

```
# Packages nécessaires
library(ggplot2)
library(ggpubr)
library(GGally)
library(invgamma)
```

1 Introduction

Nous souhaitons ici étudier un processus gamma X non homogène, et plus particulièrement ses paramètres. Pour cela, nous supposons que ce processus possède un *paramètre de forme* $a(t) = \alpha t^\beta$, avec $\alpha, \beta > 0$, et un *paramètre d'échelle* $\theta > 0$. Nous supposons aussi que, pour tous $t > s \geq 0$, $X(t) - X(s) \sim \mathcal{G}(a(t) - a(s), \theta)$ et nous posons alors, pour tout $x \in \mathbb{R}_+$, $f_{a(t)-a(s), \theta}(x) = \frac{x^{a(t)-a(s)-1}}{\theta^{a(t)-a(s)} \Gamma(a(t) - a(s))} e^{-\frac{x}{\theta}}$.

Par la construction d'une inférence bayésienne, nous allons donc chercher à estimer les trois paramètres introduits α , β et θ . Afin d'analyser la pertinence de l'approche bayésienne face à un problème de ce type, nous avons séparé notre analyse en deux phases : i) la simulation du processus selon différentes valeurs de α , β et θ afin d'observer leur impact respectif, et ii) l'étude de la pertinence de l'inférence bayésienne, en la comparant notamment à l'estimation par maximum de vraisemblance.

2 Simulations du processus

Afin de vérifier l'effet théorique de chaque paramètre sur le processus, nous regardons individuellement l'impact de chacun. Pour cela, nous définissons 2 fonctions qui vont nous permettre de réaliser les simulations tout au long de ce rapport :

- La fonction `simulations`, qui prend en entrée les paramètres α , β et θ du processus gamma ainsi que la taille des pas de simulation et d'inspection, et qui retourne une liste des grilles de pas (simulation et inspection) et du processus simulé à partir de celles-ci (simulation et inspection).
- La fonction `plot_simulations`, qui prend en entrée la sortie de `simulations` et qui retourne le graphique du processus associé, en distinguant les points simulés des points inspectés.

```
# Fonction pour simuler un processus gamma
simulations <- function(horizon = 100, dt_sim = 0.01, dt_insp = 5, alpha, beta, theta){
  # Simulations du processus continu, avec un pas de simulation dt_sim
  grille_sim <- seq(0, horizon, by = dt_sim)
  a <- function(t) {alpha*t^beta} # val de a(t)
  shape <- diff(a(grille_sim)) # a(t) - a(s)
  increments <- rgamma(length(shape), shape=shape, scale=theta)
  X_sim <- c(0, cumsum(increments))
  # Calcul des inspections, avec un pas d'inspection dt_insp
  grille_insp <- seq(0, horizon, by = dt_insp)
  n <- dt_insp / dt_sim
  X_insp <- X_sim[seq(1, length(X_sim), by = n)]
  # Résultats
  list(
    grille_sim = grille_sim, X_sim = X_sim,      # Résultats simulés
    grille_insp = grille_insp, X_insp = X_insp    # Résultats inspectés
  )
}

# Fonction graphique d'un processus
plot_simulations <- function(simulations, subtitle = "") {
  ggplot() +
```

```

geom_line(
  aes(x = simulations$grille_sim, y = simulations$X_sim, col = "Simulées")
) +
geom_point(
  aes(x = simulations$grille_insp, y = simulations$X_insp, col = "Inspectées"),
  shape = 18, size = 2
) +
scale_color_manual(
  name = "Type de données",
  values = c("Simulées" = "#2d0569", "Inspectées" = "#e3573e"),
) +
labs(x = "t", y = expression(X[t]), subtitle = subtitle) +
theme_light() +
theme(
  axis.title = element_text(size = 10, face = "bold"),
  axis.text = element_text(size = 8),
  panel.border = element_blank(),
  axis.line = element_line(colour = "darkgrey"),
  panel.grid.minor = element_blank(),
  panel.grid.major = element_line(color = "grey85"),
  legend.title = element_text(size = 10, face = "bold"),
  legend.text = element_text(size = 8),
  legend.position = "right"
)
}

```

2.1 Variations de α

Commençons par observer l'effet de α sur le processus. Pour cela, nous fixons les autres paramètres du modèle : nous fixons le pas de simulation à 0.01, le pas d'inspection à 5, $\beta = 1$ et $\theta = 2$. Nous prenons ensuite $\alpha \in \{0.1, 1, 10, 20\}$ afin d'observer son effet.

```

# Seed pour la reproductibilité
set.seed(1)

# Paramètres de simulations
dt_sim <- 0.01
dt_insp <- 5
beta <- 1
theta <- 2
# Valeurs de alpha
list_alpha <- c(.1, 1, 10, 20)

# Simulations selon les valeurs de alpha de list_alpha et les paramètres fixés
sim1 <- simulations(
  dt_sim = dt_sim, dt_insp = dt_insp, alpha = list_alpha[1], beta = beta, theta = theta
)
plot_sim1 <- plot_simulations(
  sim1, subtitle = bquote(alpha == .(list_alpha[1]))
)
sim2 <- simulations(
  dt_sim = dt_sim, dt_insp = dt_insp, alpha = list_alpha[2], beta = beta, theta = theta
)
plot_sim2 <- plot_simulations(
  sim2, subtitle = bquote(alpha == .(list_alpha[2]))
)
sim3 <- simulations(
  dt_sim = dt_sim, dt_insp = dt_insp, alpha = list_alpha[3], beta = beta, theta = theta
)

```

```

plot_sim3 <- plot_simulations(
  sim3, subtitle = bquote(alpha == .(list_alpha[3]))
)
sim4 <- simulations(
  dt_sim = dt_sim, dt_insp = dt_insp, alpha = list_alpha[4], beta = beta, theta = theta
)
plot_sim4 <- plot_simulations(
  sim4, subtitle = bquote(alpha == .(list_alpha[4]))
)

ggarrange(plot_sim1, plot_sim2, plot_sim3, plot_sim4, common.legend = TRUE)

```

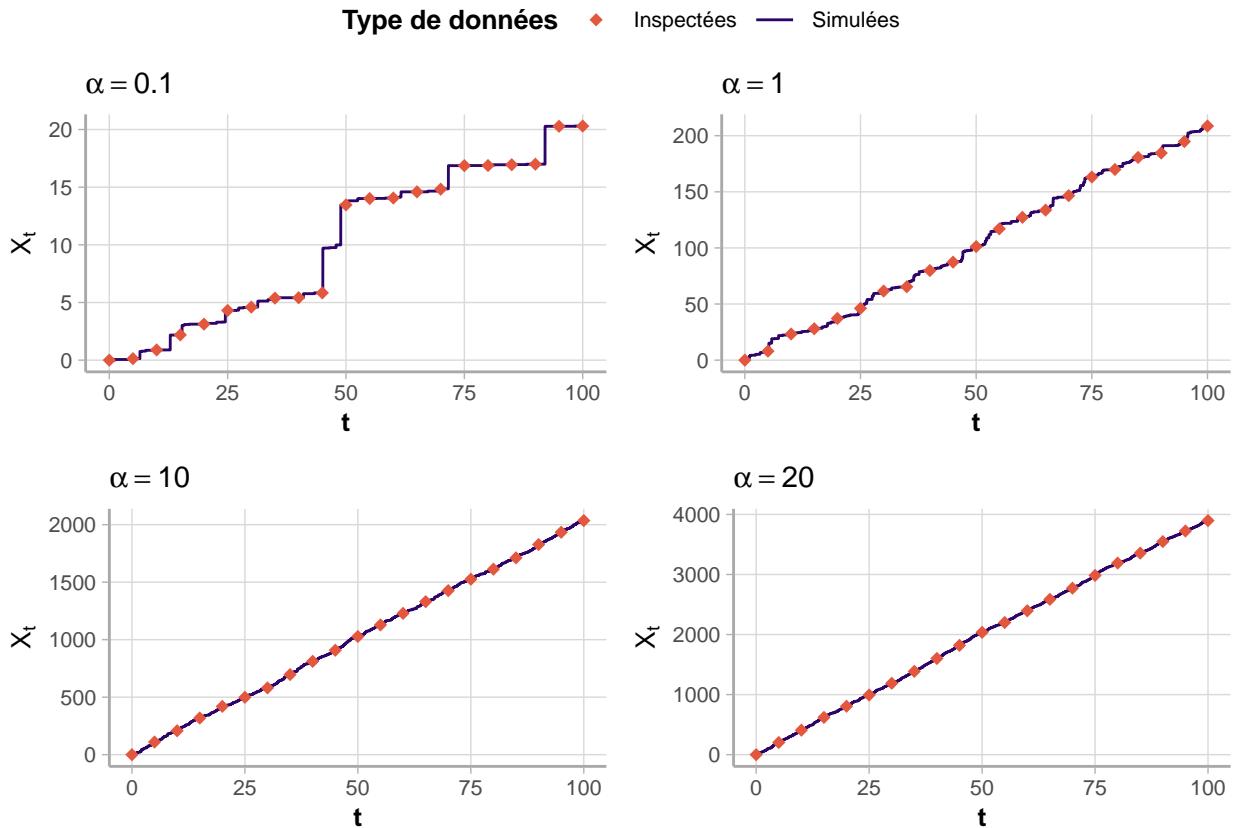


Figure 1: Simulations d'un processus gamma non-homogène ($\beta = 1, \theta = 2$) pour différents α

Nous constatons donc que α n'a pas d'impact sur la *forme* du processus, mais seulement sur l'intervalle des valeurs de X_t . La vitesse de dégradation du processus semble être proportionnel (de l'ordre de 20 000) à α : plus le paramètre est grand, plus le processus se dégrade rapidement (1).

2.2 Variations de β

Observons maintenant l'effet de β . Comme précédemment, nous fixons les autres paramètres du modèle : nous fixons le pas de simulation à 0.01, le pas d'inspection à 5, $\alpha = 1$ et $\theta = 2$. Nous prenons ensuite $\beta \in \{0.5, 1, 2, 3\}$ afin d'observer son effet.

```

# Seed pour la reproductibilité
set.seed(1)

# Paramètres de simulations
dt_sim <- 0.01
dt_insp <- 5
alpha <- 1

```

```

theta <- 2
# Valeurs de beta
list_beta <- c(0.5, 1, 2, 3)

# Simulations selon les valeurs de alpha de list_beta et les paramètres fixés
sim1 <- simulations(
  dt_sim = dt_sim, dt_insp = dt_insp, alpha = alpha, beta = list_beta[1], theta = theta
)
plot_sim1 <- plot_simulations(
  sim1, subtitle = bquote(beta == .(list_beta[1])))
)
sim2 <- simulations(
  dt_sim = dt_sim, dt_insp = dt_insp, alpha = alpha, beta = list_beta[2], theta = theta
)
plot_sim2 <- plot_simulations(
  sim2, subtitle = bquote(beta == .(list_beta[2])))
)
sim3 <- simulations(
  dt_sim = dt_sim, dt_insp = dt_insp, alpha = alpha, beta = list_beta[3], theta = theta
)
plot_sim3 <- plot_simulations(
  sim3, subtitle = bquote(beta == .(list_beta[3])))
)
sim4 <- simulations(
  dt_sim = dt_sim, dt_insp = dt_insp, alpha = alpha, beta = list_beta[4], theta = theta
)
plot_sim4 <- plot_simulations(
  sim4, subtitle = bquote(beta == .(list_beta[4])))
)

ggarrange(plot_sim1, plot_sim2, plot_sim3, plot_sim4, common.legend = TRUE)

```

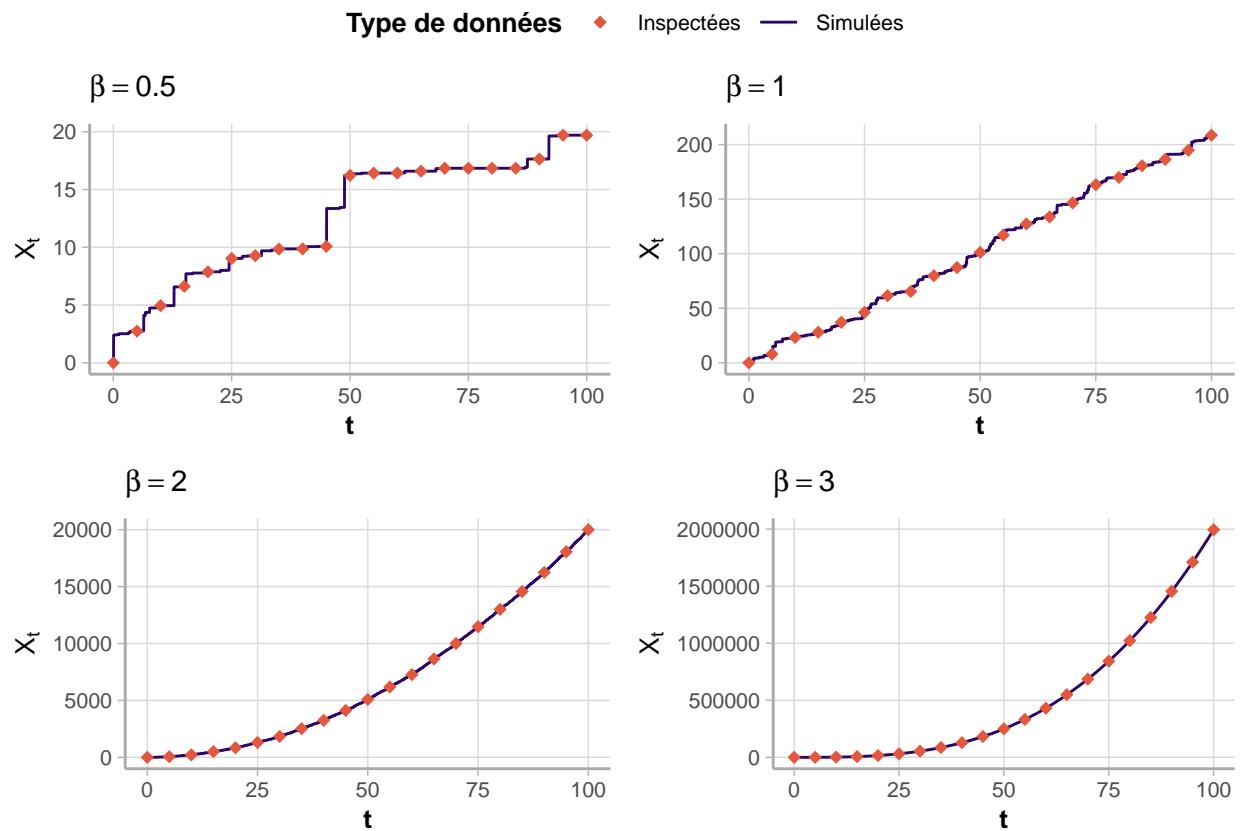


Figure 2: Simulations d'un processus gamma non-homogène ($\alpha = 1$, $\theta = 2$) pour différents β

Comme attendu, l'effet de β varie selon l'intervalle de valeurs dans lequel il se trouve :

- Pour un $\beta < 1$, la courbe est concave, i.e. la dégradation ralentit au cours du temps.
- Pour $\beta = 1$, la courbe est linéaire, i.e. la dégradation évolue toujours de la même manière au cours du temps.
- Pour un $\beta > 1$, la courbe est convexe, i.e. la dégradation s'accélère au cours du temps. Nous constatons d'ailleurs que, plus β est grand, plus l'accélération de dégradation est forte (différence entre $\beta = 2$ et $\beta = 3$) (2).

2.3 Variations de θ

Observons finalement l'effet de θ . Comme précédemment, nous fixons les autres paramètres du modèle : nous fixons le pas de simulation à 0.01, le pas d'inspection à 5, $\alpha = \beta = 1$. Nous prenons ensuite $\theta \in \{0.5, 1, 2, 5\}$ afin d'observer son effet.

```
# Seed pour la reproductibilité
set.seed(1)

# Paramètres de simulations
dt_sim <- 0.01
dt_insp <- 5
alpha <- 1
beta <- 1
# Valeurs de theta
list_theta <- c(0.5, 1, 2, 5)

# Simulations selon les valeurs de alpha de list_beta et les paramètres fixés
sim1 <- simulations(
  dt_sim = dt_sim, dt_insp = dt_insp, alpha = alpha, beta = beta, theta = list_theta[1]
)
plot_sim1 <- plot_simulations(
  sim1, subtitle = bquote(theta == .(list_theta[1]))
)
sim2 <- simulations(
  dt_sim = dt_sim, dt_insp = dt_insp, alpha = alpha, beta = beta, theta = list_theta[2]
)
plot_sim2 <- plot_simulations(
  sim2, subtitle = bquote(theta == .(list_theta[2]))
)
sim3 <- simulations(
  dt_sim = dt_sim, dt_insp = dt_insp, alpha = alpha, beta = beta, theta = list_theta[3]
)
plot_sim3 <- plot_simulations(
  sim3, subtitle = bquote(theta == .(list_theta[3]))
)
sim4 <- simulations(
  dt_sim = dt_sim, dt_insp = dt_insp, alpha = alpha, beta = beta, theta = list_theta[4]
)
plot_sim4 <- plot_simulations(
  sim4, subtitle = bquote(theta == .(list_theta[4]))
)

ggarrange(plot_sim1, plot_sim2, plot_sim3, plot_sim4, common.legend = TRUE)
```

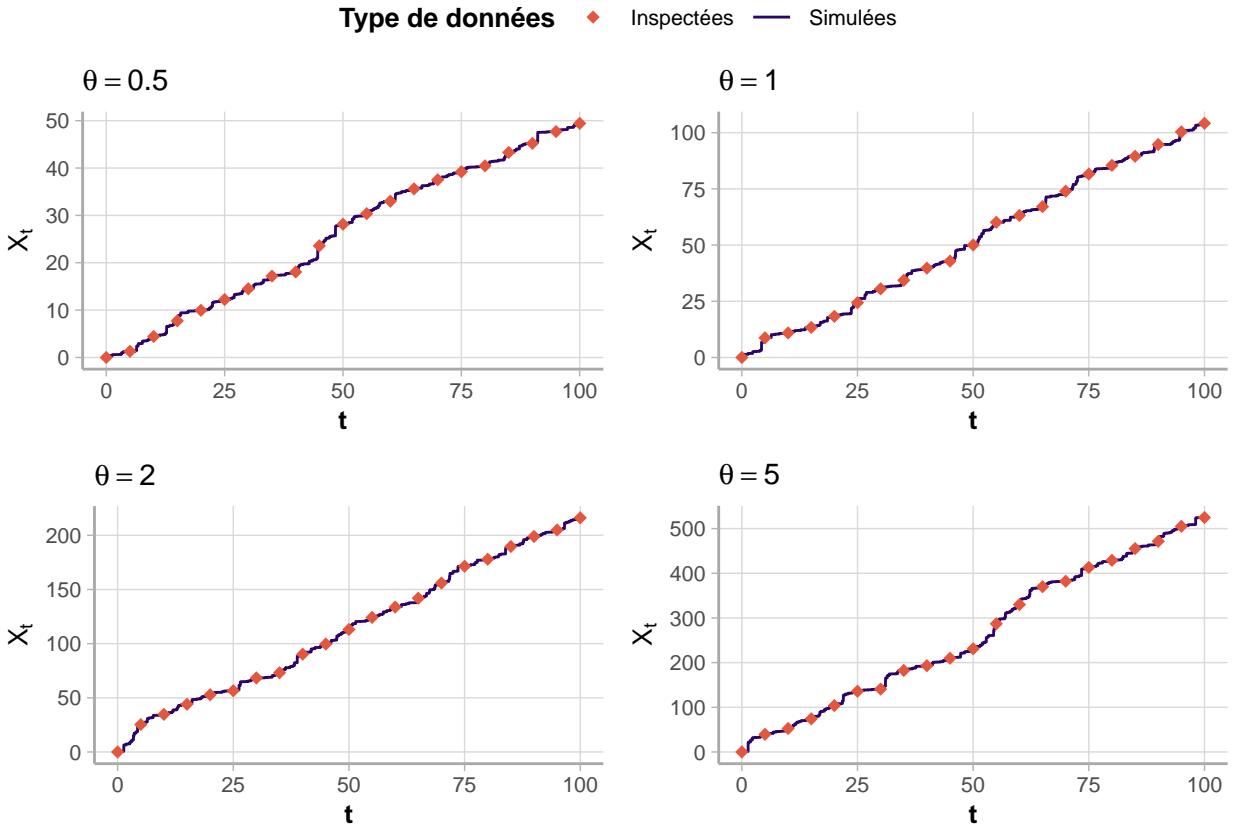


Figure 3: Simulations d'un processus gamma non-homogène ($\alpha = 1$, $\beta = 1$) pour différents θ

Comme pour α , θ ne semble pas avoir d'impact sur la *forme* du processus, mais seulement sur la vitesse de dégradation du processus. Les deux semblent encore une fois être proportionnels : plus θ est grand, plus le processus se dégrade rapidement. Toutefois, l'influence de θ semble moins forte que celle de α , le coefficient de proportionnalité étant ici de l'ordre de 100, contre 20 000 pour α (3).

3 Étude de l'inférence bayésienne

3.1 Contexte

Nous supposons maintenant que nous disposons d'un échantillon d'inspection du niveau de dégradation $x = \{x_0, \dots, x_n\}$, obtenu à différents temps d'inspection $t = \{t_0, \dots, t_n\}$ et issus d'un processus gamma non-homogène de paramètres α , β et θ . Nous souhaitons alors mettre en place une inférence bayésienne multidimensionnelle afin d'estimer ces trois paramètres d'intérêt. Nous allons donc passer par les algorithmes de Gibbs et de Metropolis-Hastings en testant différentes combinaisons de loi a priori. Les trois paramètres étant positifs, nous restreignons le choix des lois théoriques de chaque paramètre à un certain nombre de lois à support positif :

- Pour α , nous testerons soit une *loi log-normale* $\mathcal{L}\mathcal{N}(\mu, \sigma)$, soit une *loi gamma* $\mathcal{G}(k, s)$.
- Pour β nous testerons soit une *loi log-normale* $\mathcal{L}\mathcal{N}(\mu, \sigma)$, soit une *loi uniforme* $\mathcal{U}(a, b)$.
- Pour θ , nous utiliserons toujours une *loi inverse Gamma* $\mathcal{I}\mathcal{N}\mathcal{G}(a, b)$.

Nous supposons aussi par la suite que l'expert nous indique toujours une estimation μ_{exp} du paramètre à estimer (et non des paramètres de sa loi a priori) à laquelle nous associons une certaine confiance σ_{exp} . Le but de cette étude étant plutôt d'observer l'impact du choix des valeurs et des lois de chaque paramètre, nous fixerons toujours μ_{exp} et σ_{exp} en partant du principe que nous avons un bon expert à qui nous faisons confiance, i.e. μ_{exp} ne sera pas très loin de la vraie valeur du paramètre et σ_{exp} sera assez "petit".

Afin de juger de la pertinence de l'approche bayésienne, nous allons comparer ses estimations à celles obtenues par l'approche du maximum de vraisemblance. Nous calculons donc la vraisemblance du modèle.

Pour l'ensemble des lois, nous allons plutôt travailler avec les incrémentations $y_i = x_i - x_{i-1} = x_{(t_i)} - x_{(t_{i-1})}$, $i \in \{1, \dots, n\}$. Nous posons également $k_i(\alpha, \beta) = a_{(t_i)} - a_{(t_{i-1})} = \alpha(t_i^\beta - t_{i-1}^\beta)$ afin d'alléger les calculs suivants.

Par hypothèse, nous avons $X(t_i) - X(t_{i-1}) = Y_i \sim \mathcal{G}(k_i(\alpha, \beta), \theta)$, et donc :

$$f(y_i | k_i(\alpha, \beta), \theta) = \frac{1}{\Gamma(k_i(\alpha, \beta))\theta^{k_i(\alpha, \beta)}} y_i^{k_i(\alpha, \beta)-1} e^{\frac{y_i}{\theta}}$$

Puisque les incrémentations sont supposées indépendantes, la vraisemblance des données y sachant $\alpha, \beta, \theta > 0$ est donc :

$$\begin{aligned} L(y|\alpha, \beta, \theta) &= \prod_{i=1}^n f(y_i | k_i(\alpha, \beta), \theta) \\ &= \prod_{i=1}^n \frac{1}{\Gamma(k_i(\alpha, \beta))\theta^{k_i(\alpha, \beta)}} y_i^{k_i(\alpha, \beta)-1} e^{\frac{y_i}{\theta}} \end{aligned}$$

Afin de réaliser l'inférence bayésienne, nous calculons maintenant les différentes lois a posteriori avec lesquelles nous allons être amenés à travailler.

3.1.1 Calcul de la loi a posteriori pour θ

Nous avons choisi comme loi a priori pour θ une $\mathcal{I}nv\text{-}\mathcal{G}(a, b)$. Ainsi :

$$\begin{aligned} p(\theta|y, \alpha, \beta) &= L(y|\alpha, \beta, \theta) \times p(\theta) \\ &\propto \theta^{\sum k_i(\alpha, \beta)} e^{-\sum \frac{y_i}{\theta}} \theta^{-(a+1)} e^{-\frac{b}{\theta}} \\ &\propto \theta^{-(\sum k_i(\alpha, \beta)+a+1)} e^{-\sum \frac{y_i+\beta}{\theta}} \end{aligned}$$

Nous pouvons reconnaître, à une constante de normalisation près, la densité d'une $\mathcal{I}nv\text{-}\mathcal{G}(a + \sum k_i(\alpha, \beta), b + \sum y_i)$. Nous pourrons donc estimer θ avec un algorithme de Gibbs.

En supposant que les paramètres d'expert μ_θ et σ_θ correspondent à $\mu_\theta = \mathbb{E}[\mathcal{I}nv\text{-}\mathcal{G}(a, b)] = \frac{b}{a-1}$ et $\sigma_\theta = \sqrt{Var(\mathcal{I}nv\text{-}\mathcal{G}(a, b))} = \frac{b^2}{(a-1)^2(a-2)}$, nous avons alors :

$$\begin{cases} a = \frac{\mu_\theta^2}{\sigma_\theta^2} + 2 \\ b = (a-1)\mu_\theta \end{cases} .$$

3.1.2 Calcul des lois a posteriori pour α

1. Calcul pour une $\mathcal{L}og\text{-}\mathcal{N}(\mu, \sigma)$.

$$\begin{aligned} \text{Nous avons : } p(\alpha|y, \beta, \theta) &= L(y|\alpha, \beta, \theta) \times p(\alpha) \\ &\propto \frac{1}{\alpha \sigma \sqrt{2\pi}} e^{-\frac{(ln(\alpha) - \mu)^2}{2\sigma^2}} \prod_i \frac{1}{\Gamma(k_i(\alpha, \beta))\theta^{k_i(\alpha, \beta)}} y_i^{k_i(\alpha, \beta)} \end{aligned}$$

Comme nous ne reconnaissions pas de forme de loi usuelle, nous allons utiliser l'algorithme de Metropolis-Hastings. Pour faciliter le calcul numérique, nous regardons $ln(p(\alpha|y, \beta, \theta)) - ln(p(\alpha^{(k-1)}|y, \beta, \theta))$ plutôt que le rapport $\frac{p(\tilde{\alpha}|y, \beta, \theta)}{p(\alpha^{(k-1)}|y, \beta, \theta)}$. Nous avons donc :

$$ln(p(\alpha|y, \beta, \theta)) = -ln(\alpha) - \frac{(ln(\alpha) - \mu)^2}{2\sigma^2} + \sum_{i=1}^n (k_i(\alpha, \beta) - 1)ln(y_i) - k_i(\alpha, \beta)ln(\theta) - ln(\Gamma(k_i(\alpha, \beta))) + \text{cste}$$

En supposant que les paramètres d'expert μ_α et σ_α correspondent à $\mu_\alpha = \mathbb{E}[\mathcal{L}og\text{-}\mathcal{N}(\mu, \sigma)] = e^{\frac{\mu+\sigma^2}{2}}$ et $\sigma_\alpha = \sqrt{Var(\mathcal{L}og\text{-}\mathcal{N}(\mu, \sigma))} = (e^{\sigma^2} - 1)e^{2\mu+\sigma^2}$, nous avons alors :

$$\begin{cases} \mu = ln(\mu_\alpha) - \frac{ln(1 + \frac{\sigma_\alpha}{\mu_\alpha^2})}{2} \\ \sigma = \sqrt{ln(\frac{\sigma_\alpha}{\mu_\alpha^2} + 1)} \end{cases} .$$

2. Calcul pour une $\mathcal{G}(k, s)$.

Nous avons :

$$p(\alpha|y, \beta, \theta) = L(y|\alpha, \beta, \theta) \times p(\alpha)$$

$$\propto \frac{1}{\Gamma(k)s^k} \alpha^{k-1} e^{-\alpha/s} \prod_i \frac{1}{\Gamma(k_i(\alpha, \beta))\theta^{k_i(\alpha, \beta)}} y_i^{k_i(\alpha, \beta)}$$

Encore une fois, nous ne reconnaissions pas de forme de loi usuelle. Nous allons donc utiliser l'algorithme de Metropolis-Hasting. Pour faciliter le calcul numérique, nous regardons $\ln(p(\tilde{\alpha}|y, \beta, \theta)) - \ln(p(\alpha^{(k-1)}|y, \beta, \theta))$ plutôt que le rapport $\frac{p(\tilde{\alpha}|y, \beta, \theta)}{p(\alpha^{(k-1)}|y, \beta, \theta)}$. Nous avons donc :

$$\ln(p(\alpha|y, \beta, \theta)) = (k-1)\ln(\alpha) - \frac{\alpha}{s} + \sum_{i=1}^n (k_i(\alpha, \beta) - 1)\ln(y_i) - k_i(\alpha, \beta)\ln(\theta) - \ln(\Gamma(k_i(\alpha, \beta))) + \text{cste}$$

En supposant que les paramètres d'expert μ_α et σ_α correspondent à $\mu_\alpha = \mathbb{E}[\mathcal{G}(k, s)] = \frac{k}{s}$ et $\sigma_\alpha = \text{Var}(\mathcal{G}(k, s)) = \frac{k}{s^2}$, nous avons alors :

$$\begin{cases} k = \frac{\mu_\alpha^2}{\sigma_\alpha^2} \\ s = \frac{\sigma_\alpha^2}{\mu_\alpha} \end{cases} .$$

3.1.3 Calcul des lois a posteriori pour β

1. Calcul pour une $\mathcal{N}(\mu, \sigma)$.

Par inversion des rôles entre α et β , nous retrouvons les résultats déjà exhibés plus haut. Nous avons donc :

$$\begin{cases} \mu = \ln(\mu_\beta) - \frac{\ln(1 + \frac{\sigma_\beta}{\mu_\beta^2})}{2} \\ \sigma = \sqrt{\ln(\frac{\sigma_\beta^2}{\mu_\beta^2} + 1)} \end{cases} .$$

2. Calcul pour une $\mathcal{U}(a, b)$.

Nous avons :

$$p(\beta|y, \alpha, \theta) = L(y|\alpha, \beta, \theta) \times p(\beta)$$

$$\propto \mathbf{1}_{\beta \in [a, b]} \prod_i \frac{1}{\Gamma(k_i(\alpha, \beta))\theta^{k_i(\alpha, \beta)}} y_i^{k_i(\alpha, \beta)}$$

Encore une fois, nous ne reconnaissions pas de forme de loi usuelle. Nous allons donc utiliser l'algorithme de Metropolis-Hasting. Pour faciliter le calcul numérique, nous regardons $\log(p(\tilde{\beta}|y, \alpha, \theta)) - \log(p(\beta^{(k-1)}|y, \alpha, \theta))$ plutôt que le rapport $\frac{p(\tilde{\beta}|y, \alpha, \theta)}{p(\beta^{(k-1)}|y, \alpha, \theta)}$. Nous avons donc :

$$\ln(p(\beta|y, \alpha, \theta)) = \begin{cases} \sum_{i=1}^n (k_i(\alpha, \beta) - 1)\ln(y_i) - k_i(\alpha, \beta)\ln(\theta) - \ln(\Gamma(k_i(\alpha, \beta))) + \text{cste} & \text{si } \beta \in [a, b] \\ -\infty & \text{sinon} \end{cases} .$$

En supposant que les paramètres d'expert μ_β et σ_β correspondent à $\mu_\beta = \mathbb{E}[\mathcal{U}(a, b)] = \frac{a+b}{2}$ et $\sigma_\beta = \text{Var}(\mathcal{U}(a, b)) = \frac{(a-b)^2}{12}$, nous avons alors :

$$\begin{cases} a = \mu_\beta - \sqrt{3\sigma_\beta} \\ b = \mu_\beta + \sqrt{3\sigma_\beta} \end{cases} .$$

3.1.4 Remarque

Dans l'algorithme de Metropolis-Hasting, nous choisissons comme distribution instrumentale pour α (resp. β) une loi normale centrée en $\alpha^{(k-1)}$ (resp. $\beta^{(k-1)}$) afin de se ramener à un rapport des lois a posteriori entre la nouvelle valeur $\tilde{\alpha}$ (resp. $\tilde{\beta}$) et l'ancienne valeur $\alpha^{(k-1)}$ (resp. $\beta^{(k-1)}$). Nous notons τ_α (resp. τ_β) la variance de cette loi.

3.2 Fonctions

Afin de fluidifier notre analyse, nous avons implémenté un certain nombre de fonctions utiles à l'étude.

3.2.1 Lois a posteriori

Nous avons implémenté une fonction pour chacune des lois a posteriori de α et β calculées plus haut. Nous avons aussi implémenté une fonction pour calculer les $k_i(\alpha, \beta)$ introduits précédemment.

```
# Fonction de calcul des k_i
func_list_ki <- function(alpha, beta, t_insp) {
  n <- length(t_insp) - 1
  alpha * (t_insp[2:(n+1)]^beta - t_insp[1:n]^beta)
}

# Lois a posteriori pour alpha
### Log-normale(mu,sigma)
logpost_alpha_lognormale <- function(alpha, y, t_insp, beta, theta, mu_alpha, sigma_alpha) {
  mu <- log(mu_alpha) - 0.5 * log(1 + sigma_alpha/(mu_alpha^2))
  sigma <- sqrt(log(1 + sigma_alpha/(mu_alpha^2)))
  list_ki <- func_list_ki(alpha, beta, t_insp)
  -log(alpha) - ((log(alpha)-mu)^2)/(2*sigma^2) +
    sum((list_ki - 1)*log(y) - list_ki*log(theta) - lgamma(list_ki))
}

### Gamma(k,s)
logpost_alpha_gamma <- function(alpha, y, t_insp, beta, theta, mu_alpha, sigma_alpha) {
  k <- mu_alpha^2 / sigma_alpha
  s <- mu_alpha / sigma_alpha
  list_ki <- func_list_ki(alpha, beta, t_insp)
  (k-1)*log(alpha) - alpha/s +
    sum((list_ki - 1)*log(y) - list_ki*log(theta) - lgamma(list_ki))
}

# Lois a posteriori pour beta
### Log-normale(mu,sigma)
logpost_beta_lognormale <- function(beta, y, t_insp, alpha, theta, mu_beta, sigma_beta) {
  mu <- log(mu_beta) - 0.5 * log(1 + sigma_beta/(mu_beta^2))
  sigma <- sqrt(log(1 + sigma_beta/(mu_beta^2)))
  list_ki <- func_list_ki(alpha, beta, t_insp)
  -log(beta) - ((log(beta)-mu)^2)/(2*sigma^2) +
    sum((list_ki - 1)*log(y) - list_ki*log(theta) - lgamma(list_ki))
}

### Uniforme(a,b)
logpost_beta_unif <- function(beta, y, t_insp, alpha, theta, mu_beta, sigma_beta) {
  a <- mu_beta - sqrt(3*sigma_beta)
  b <- mu_beta + sqrt(3*sigma_beta)
  if (beta < a || beta > b) {
    -Inf
  } else {
    list_ki <- func_list_ki(alpha, beta, t_insp)
    sum((list_ki - 1)*log(y) - list_ki*log(theta) - lgamma(list_ki))
  }
}
```

3.2.2 Algorithme de Gibbs-Metropolis-Hastings (GMH)

La fonction `algo_GMH` implémente un algorithme MCMC de type Gibbs–Metropolis–Hastings (GMH) permettant d'obtenir K estimations bayésienne de chaque paramètre (α , β et θ). Elle prend en entrée la liste d'arguments suivant :

- `logpost_par` : fonction pour le calcul de $\log(\text{posteriori}(\bar{p}))$.
- `mu_par` : moyenne de l'expert pour le paramètre `par`.
- `sigma_par` : confiance en l'expert pour le paramètre `par`.
- `tau_par` : variation de la normale pour le paramètre `par`.
- `par0` : initialisation du paramètre `par` pour chaîne de markov.
- `data` : x_1, \dots, x_n observations (à transformer en y_1, \dots, y_n) les incrémentations.
- `t_insp` : t_1, \dots, t_n les temps d'inspection.
- `K` : nombre d'itérations des algorithmes.
- `burnin` : nombre d'itérations à supprimer au début.

```

algo_GMH <- function(
  logpost_alpha, mu_alpha, sigma_alpha, tau_alpha, alpha0,
  logpost_beta, mu_beta, sigma_beta, tau_beta, beta0,
  mu_theta, sigma_theta, theta0, data, t_insp, K, burnin
) {
  # Transformation des données en incrémentations  $y_i = x(t_i) - x(t_{i-1})$ 
  y <- data[2:length(data)] - data[1:length(data)-1]
  n <- length(y)
  # Calcul du a et b pour simuler theta
  a_theta <- mu_theta^2 / sigma_theta + 2
  b_theta <- (a_theta-1) * mu_theta
  # Initialisation des vecteurs de résultats
  res_alpha <- numeric(K+1)
  res_alpha[1] <- alpha0
  res_beta <- numeric(K+1)
  res_beta[1] <- beta0
  res_theta <- numeric(K+1)
  res_theta[1] <- theta0
  # Boucle sur k pour calculer de  $\alpha^{(k)}$ ,  $\beta^{(k)}$  et  $\theta^{(k)}$ 
  for(k in 2:(K+1)) {
    # 1. Simulation de  $\theta^{(k)}$ 
    list_ki <- func_list_ki(res_alpha[k-1], res_beta[k-1], t_insp)
    a_bis <- a_theta + sum(list_ki)
    b_bis <- b_theta + sum(y)
    theta_hat_moment <- sum(y) / sum(list_ki)
    res_theta[k] <- 1 / rgamma(1, shape = a_bis, rate = b_bis)
    # 2. Simulation de  $\alpha^{(k)}$  (MH)
    alpha_tilde <- rnorm(1, mean = res_alpha[k-1], sd = tau_alpha)
    if(alpha_tilde <= 0){
      res_alpha[k] <- res_alpha[k-1]
    }
    else {
      first_log <- logpost_alpha(
        alpha_tilde, y, t_insp, res_beta[k-1], res_theta[k], mu_alpha, sigma_alpha
      )
      second_log <- logpost_alpha(
        res_alpha[k-1], y, t_insp, res_beta[k-1], res_theta[k], mu_alpha, sigma_alpha
      )
      log_r <- first_log - second_log
      u <- runif(1)
      res_alpha[k] <- ifelse(log(u) <= log_r, alpha_tilde, res_alpha[k-1])
    }
    # 3. Simulation de  $\beta^{(k)}$  (MH)
    beta_tilde <- rnorm(1, mean = res_beta[k-1], sd = tau_beta)
    if(beta_tilde <= 0){
      res_beta[k] <- res_beta[k-1]
    }
    else {
      first_log <- logpost_beta(
        beta_tilde, y, t_insp, res_alpha[k], res_theta[k], mu_beta, sigma_beta
      )
      second_log <- logpost_beta(
        res_beta[k-1], y, t_insp, res_alpha[k], res_theta[k], mu_beta, sigma_beta
      )
    }
  }
}

```

```

    )
    log_r <- first_log - second_log
    u <- runif(1)
    res_beta[k] <- ifelse(log(u) <= log_r, beta_tilde, res_beta[k-1])
}
}

# Résultats avec burnin
return(list(
  res_theta = tail(res_theta, n = K-burnin),
  res_alpha = tail(res_alpha, n = K-burnin),
  res_beta = tail(res_beta, n = K-burnin))
)
}
}

```

3.2.3 Estimateurs du maximum de vraisemblance (MLE) par optimisation

Afin d'obtenir les MLE, nous cherchons à minimiser $-\ln(Vraisemblance)$. Nous implémentons donc d'abord une fonction permettant de retourner cette objet (`neg_vraisemblance`), puis nous implémentons une fonction permettant d'exhiber les MLE obtenus (`mle`).

```

# -Vraisemblance
neg_vraisemblance <- function(vect_param, y, t_insp) {
  alpha <- vect_param[1]
  beta <- vect_param[2]
  theta <- vect_param[3]
  list_ki <- func_list_ki(alpha, beta, t_insp)
  if (any(!is.finite(list_ki)) || any(list_ki <= 0) || !is.finite(theta) || theta <= 0) {
    1e100
  } else if (any(!is.finite(y)) || any(y <= 0)) {
    1e100
  } else {
    -(sum((list_ki - 1) * log(y) - (y/theta) - list_ki * log(theta) - lgamma(list_ki)))
  }
}

# Calcul des MLE via optimisation
mle <- function(alpha0, beta0, theta0, data, t_insp) {
  y <- data[2:length(data)] - data[1:(length(data)-1)]
  init <- c(alpha0, beta0, theta0)
  fit <- optim(
    par = init,
    fn = neg_vraisemblance,
    y = y,
    t_insp = t_insp,
    method = "BFGS",
    control = list(maxit = 5000, reltol = 1e-10)
  )
  list(
    alpha = fit$par[1],
    beta = fit$par[2],
    theta = fit$par[3],
    converged = (fit$convergence == 0)
  )
}

```

3.2.4 Fonction de visualisation

Nous implémentons finalement une fonction nous permettant de visualiser les résultat obtenus simultanément (`vis_res`). Elle nous permettra notamment de comparer les vrais données aux estimations bayésiennes et par maximum de vraisemblance.

```
vis_res <- function(res_GMH, res_MLE, sim_og, subtitle = "") {
  # Récupération des hyperparamètres de la simulation originale en jeu
  horizon <- sim_og$grille_sim[length(sim_og$grille_sim)]
  dt_sim <- sim_og$grille_sim[2] - sim_og$grille_sim[1]
  dt_insp <- sim_og$grille_insp[2] - sim_og$grille_insp[1]
  # Simulation du processus avec les paramètres estimés par GMH
  alpha_GMH <- mean(res_GMH$res_alpha)
  beta_GMH <- mean(res_GMH$res_beta)
  theta_GMH <- mean(res_GMH$res_theta)
  simulations_GMH <- simulations(
    horizon, dt_sim, dt_insp, alpha = alpha_GMH, beta = beta_GMH, theta = theta_GMH
  )
  # Simulation du processus avec les paramètres estimés par maximum de vraisemblance
  alpha_MLE <- res_MLE$alpha
  beta_MLE <- res_MLE$beta
  theta_MLE <- res_MLE$theta
  simulations_MLE <- simulations(
    horizon, dt_sim, dt_insp, alpha = alpha_MLE, beta = beta_MLE, theta = theta_MLE
  )
  # Dataframe des résultats au format "long" (pour ggplot)
  df_long <- data.frame(
    grille_sim = sim_og$grille_sim,
    X_sim = sim_og$X_sim,
    X_sim_GMH = simulations_GMH$X_sim,
    X_sim_MLE = simulations_MLE$X_sim
  )
  # Visualisation des résultats sur une même figure
  ggplot() +
    geom_line(aes(
      x = df_long$grille_sim, y = df_long$X_sim,
      col = "Processus original"
    )) +
    geom_line(aes(
      x = df_long$grille_sim, y = df_long$X_sim_GMH,
      col = "GMH"
    )) +
    geom_line(aes(
      x = df_long$grille_sim, y = df_long$X_sim_MLE,
      col = "MLE"
    )) +
    scale_color_manual(
      name = "Données",
      values = c(
        "Processus original" = "#e3573e",
        "GMH" = "#49a86c",
        "MLE" = "#2d0569"
      ),
    ) +
    labs(x = "t", y = expression(X[t]), subtitle = subtitle) +
    theme_light() +
    theme(
      axis.title = element_text(size = 10, face = "bold"),
      axis.text = element_text(size = 8),
      panel.border = element_blank(),
      axis.line = element_line(colour = "darkgrey"),
      panel.grid.minor = element_blank(),
      panel.grid.major = element_line(color = "grey85"),
    )
}
```

```

        legend.title = element_text(size = 10, face = "bold"),
        legend.text = element_text(size = 8),
        legend.position = "right"
    )
}

```

3.3 Résultats

D'après nos constats précédents (partie **Simulations du processus**), l'influence de α et θ est assez faible sur la courbe du processus ; ils n'agissent que sur un coefficient de proportionnalité, et non sur la forme générale. À l'inverse, β module la forme de la courbe selon trois cas : $\beta < 1$, $\beta = 1$ et $\beta > 1$. Nous allons donc distinguer ces trois cas afin d'analyser et comparer les estimations bayésiennes et par maximum de vraisemblance. Afin de garder une cohérence entre les résultats, nous fixons l'ensemble des autres paramètres de simulations à une valeur fixe :

```

# Paramètres de simulation
dt_sim <- 0.01
dt_insp <- 5
alpha <- 1
theta <- 2
# Paramètres de l'algorithme GMH
K <- 10000
burnin <- 1000

```

Nous fixons aussi les données relatives à l'expert pour α et θ : nous considérons le cas où il est bon et où nous lui faisons confiance :

```

# Bonne confiance en un expert bon
### Expertise sur alpha
mu_alpha <- alpha + 0.2
sigma_alpha <- 1
tau_alpha <- 0.3
alpha0 <- mu_alpha
### Expertise sur theta
mu_theta <- theta + 0.2
sigma_theta <- 1
theta0 <- mu_theta

```

3.3.1 $\beta < 1$, cas concave

Commençons par regarder le cas où $\beta < 1$, par exemple $\beta = 0.5$. Comme pour α et θ , nous considérons le cas où l'expert est bon et où nous lui faisons confiance pour l'expertise de β .

```

# Seed pour la reproductibilité
set.seed(1)

# 1. Simulation du processus
beta <- 0.5
sim_og <- simulations(
  dt_sim = dt_sim, dt_insp = dt_insp, alpha = alpha, beta = beta, theta = theta
)
data <- sim_og$X_insp
t_insp <- sim_og$grille_insp
### Expertise sur beta : bonne confiance en un expert bon
mu_beta <- beta + 0.2

```

```

sigma_beta <- 1
tau_beta <- 0.3
beta0 <- mu_beta

# 2. alpha ~ Log-normale et beta ~ Log-normale
res_GMH <- algo_GMH(
  logpost_alpha_lognormale, mu_alpha, sigma_alpha, tau_alpha, alpha0,
  logpost_beta_lognormale, mu_beta, sigma_beta, tau_beta, beta0,
  mu_theta, sigma_theta, theta0, data, t_insp, K, burnin
)
res_MLE <- mle(alpha0, beta0, theta0, data, t_insp)
plot1 <- vis_res(
  res_GMH, res_MLE, sim_og,
  subtitle = expression(alpha %~% "Log-N" ~ "et" ~ beta %~% "Log-N")
)

# 3. alpha ~ Gamma et beta ~ Lognormale
res_GMH <- algo_GMH(
  logpost_alpha_gamma, mu_alpha, sigma_alpha, tau_alpha, alpha0,
  logpost_beta_lognormale, mu_beta, sigma_beta, tau_beta, beta0,
  mu_theta, sigma_theta, theta0, data, t_insp, K, burnin
)
res_MLE <- mle(alpha0, beta0, theta0, data, t_insp)
plot2 <- vis_res(
  res_GMH, res_MLE, sim_og,
  subtitle = expression(alpha %~% "Gamma" ~ "et" ~ beta %~% "Log-N")
)

# 3. alpha ~ Log-normale et beta ~ Uniforme
res_GMH <- algo_GMH(
  logpost_alpha_lognormale, mu_alpha, sigma_alpha, tau_alpha, alpha0,
  logpost_beta_unif, mu_beta, sigma_beta, tau_beta, beta0,
  mu_theta, sigma_theta, theta0, data, t_insp, K, burnin
)
res_MLE <- mle(alpha0, beta0, theta0, data, t_insp)
plot3 <- vis_res(
  res_GMH, res_MLE, sim_og,
  subtitle = expression(alpha %~% "Log-N" ~ "et" ~ beta %~% "Uniforme")
)

# 4. alpha ~ Gamma et beta ~ Uniforme
res_GMH <- algo_GMH(
  logpost_alpha_gamma, mu_alpha, sigma_alpha, tau_alpha, alpha0,
  logpost_beta_unif, mu_beta, sigma_beta, tau_beta, beta0,
  mu_theta, sigma_theta, theta0, data, t_insp, K, burnin
)
res_MLE <- mle(alpha0, beta0, theta0, data, t_insp)
plot4 <- vis_res(
  res_GMH, res_MLE, sim_og,
  subtitle = expression(alpha %~% "Gamma" ~ "et" ~ beta %~% "Uniforme")
)

# Visualisation finale
ggarrange(plot1, plot2, plot3, plot4, common.legend = TRUE)

```

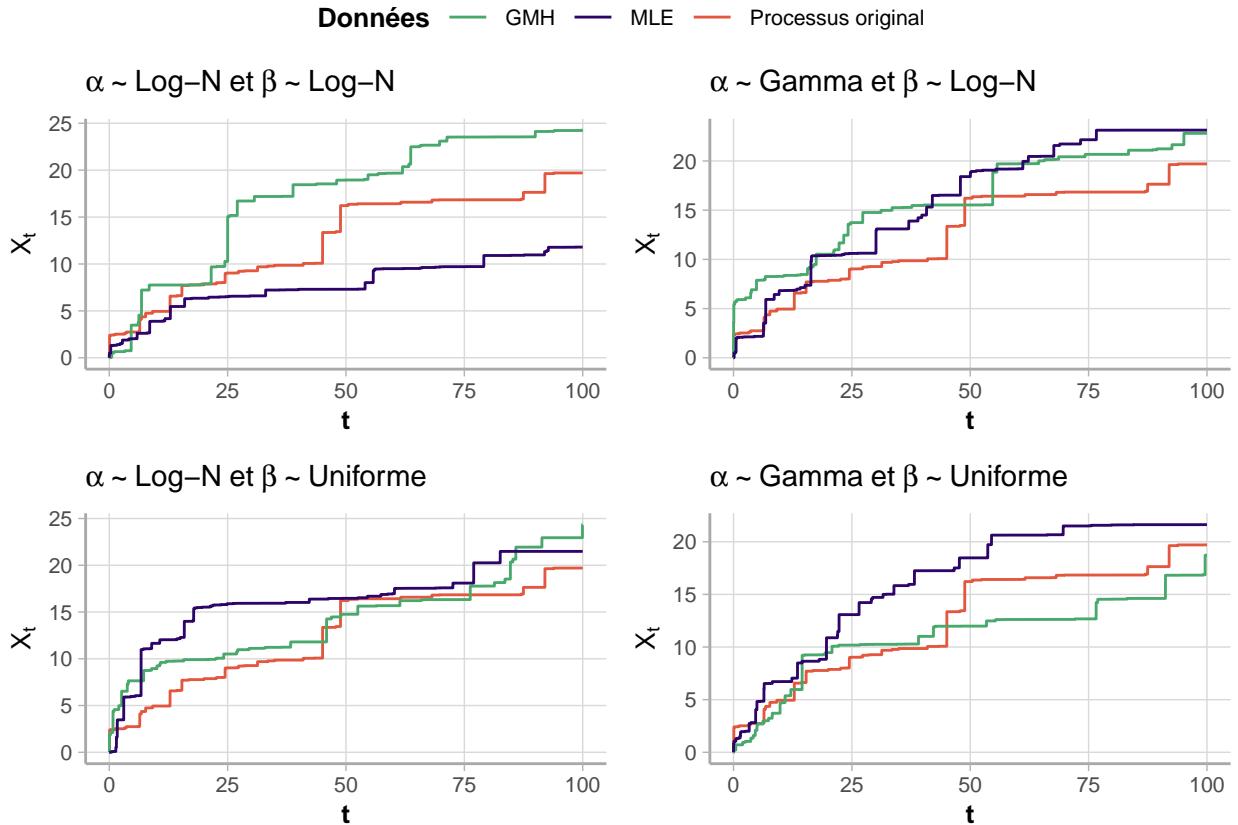


Figure 4: Résultats d'estimations bayésiennes et par maximum de vraisemblance lorsque $\beta < 1$

(4)

3.3.2 $\beta = 1$, cas linéaire

Regardons maintenant le cas où $\beta = 1$. Comme précédemment, nous considérons le cas où l'expert est bon et où nous lui faisons confiance pour l'expertise de β .

```
# Seed pour la reproductibilité
set.seed(1)

# 1. Simulation du processus
beta <- 1
sim_og <- simulations(
  dt_sim = dt_sim, dt_insp = dt_insp, alpha = alpha, beta = beta, theta = theta
)
data <- sim_og$X_insp
t_insp <- sim_og$grille_insp
### Expertise sur beta : bonne confiance en un expert bon
mu_beta <- beta + 0.2
sigma_beta <- 1
tau_beta <- 0.3
beta0 <- mu_beta

# 2. alpha ~ Log-normale et beta ~ Log-normale
res_GMH <- algo_GMH(
  logpost_alpha_lognormale, mu_alpha, sigma_alpha, tau_alpha, alpha0,
  logpost_beta_lognormale, mu_beta, sigma_beta, tau_beta, beta0,
  mu_theta, sigma_theta, theta0, data, t_insp, K, burnin
)
res_MLE <- mle(alpha0, beta0, theta0, data, t_insp)
plot1 <- vis_res(
```

```

res_GMH, res_MLE, sim_og,
subtitle = expression(alpha %~% "Log-N" ~ "et" ~ beta %~% "Log-N")
)

# 3. alpha ~ Gamma et beta ~ Lognormale
res_GMH <- algo_GMH(
  logpost_alpha_gamma, mu_alpha, sigma_alpha, tau_alpha, alpha0,
  logpost_beta_lognormale, mu_beta, sigma_beta, tau_beta, beta0,
  mu_theta, sigma_theta, theta0, data, t_insp, K, burnin
)
res_MLE <- mle(alpha0, beta0, theta0, data, t_insp)
plot2 <- vis_res(
  res_GMH, res_MLE, sim_og,
  subtitle = expression(alpha %~% "Gamma" ~ "et" ~ beta %~% "Log-N")
)

# 3. alpha ~ Log-normale et beta ~ Uniforme
res_GMH <- algo_GMH(
  logpost_alpha_lognormale, mu_alpha, sigma_alpha, tau_alpha, alpha0,
  logpost_beta_unif, mu_beta, sigma_beta, tau_beta, beta0,
  mu_theta, sigma_theta, theta0, data, t_insp, K, burnin
)
res_MLE <- mle(alpha0, beta0, theta0, data, t_insp)
plot3 <- vis_res(
  res_GMH, res_MLE, sim_og,
  subtitle = expression(alpha %~% "log-N" ~ "et" ~ beta %~% "Uniforme")
)

# 4. alpha ~ Gamma et beta ~ Uniforme
res_GMH <- algo_GMH(
  logpost_alpha_gamma, mu_alpha, sigma_alpha, tau_alpha, alpha0,
  logpost_beta_unif, mu_beta, sigma_beta, tau_beta, beta0,
  mu_theta, sigma_theta, theta0, data, t_insp, K, burnin
)
res_MLE <- mle(alpha0, beta0, theta0, data, t_insp)
plot4 <- vis_res(
  res_GMH, res_MLE, sim_og,
  subtitle = expression(alpha %~% "Gamma" ~ "et" ~ beta %~% "Uniforme")
)

# Visualisation finale
ggarrange(plot1, plot2, plot3, plot4, common.legend = TRUE)

```

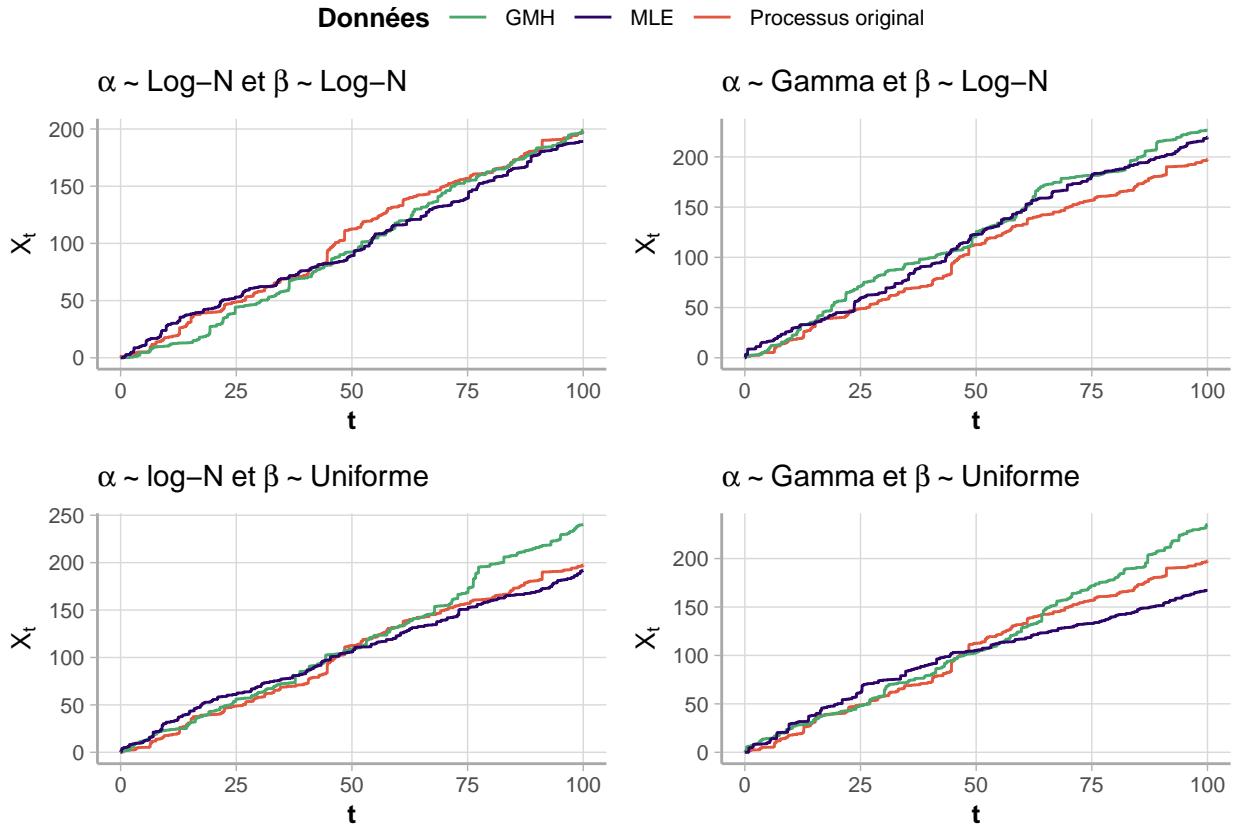


Figure 5: Résultats d'estimations bayésiennes et par maximum de vraisemblance lorsque $\beta = 1$

(5)

3.3.3 $\beta > 1$, cas convexe

Regardons finalement le cas où $\beta > 1$, par exemple $\beta = 3$. Comme précédemment, nous considérons le cas où l'expert est bon et où nous lui faisons confiance pour l'expertise de β .

```
# Seed pour la reproductibilité
set.seed(1)

# 1. Simulation du processus
beta <- 3
sim_og <- simulations(
  dt_sim = dt_sim, dt_insp = dt_insp, alpha = alpha, beta = beta, theta = theta
)
data <- sim_og$X_insp
t_insp <- sim_og$grille_insp
### Expertise sur beta : bonne confiance en un expert bon
mu_beta <- beta + 0.2
sigma_beta <- 1
tau_beta <- 0.3
beta0 <- mu_beta

# 2. alpha ~ Log-normale et beta ~ Log-normale
res_GMH <- algo_GMH(
  logpost_alpha_lognormale, mu_alpha, sigma_alpha, tau_alpha, alpha0,
  logpost_beta_lognormale, mu_beta, sigma_beta, tau_beta, beta0,
  mu_theta, sigma_theta, theta0, data, t_insp, K, burnin
)
res_MLE <- mle(alpha0, beta0, theta0, data, t_insp)
plot1 <- vis_res(
```

```

res_GMH, res_MLE, sim_og,
subtitle = expression(alpha %~% "Log-N" ~ "et" ~ beta %~% "Log-N")
)

# 3. alpha ~ Gamma et beta ~ Lognormale
res_GMH <- algo_GMH(
  logpost_alpha_gamma, mu_alpha, sigma_alpha, tau_alpha, alpha0,
  logpost_beta_lognormale, mu_beta, sigma_beta, tau_beta, beta0,
  mu_theta, sigma_theta, theta0, data, t_insp, K, burnin
)
res_MLE <- mle(alpha0, beta0, theta0, data, t_insp)
plot2 <- vis_res(
  res_GMH, res_MLE, sim_og,
  subtitle = expression(alpha %~% "Gamma" ~ "et" ~ beta %~% "Log-N")
)

# 3. alpha ~ Log-normale et beta ~ Uniforme
res_GMH <- algo_GMH(
  logpost_alpha_lognormale, mu_alpha, sigma_alpha, tau_alpha, alpha0,
  logpost_beta_unif, mu_beta, sigma_beta, tau_beta, beta0,
  mu_theta, sigma_theta, theta0, data, t_insp, K, burnin
)
res_MLE <- mle(alpha0, beta0, theta0, data, t_insp)
plot3 <- vis_res(
  res_GMH, res_MLE, sim_og,
  subtitle = expression(alpha %~% "log-N" ~ "et" ~ beta %~% "Uniforme")
)

# 4. alpha ~ Gamma et beta ~ Uniforme
res_GMH <- algo_GMH(
  logpost_alpha_gamma, mu_alpha, sigma_alpha, tau_alpha, alpha0,
  logpost_beta_unif, mu_beta, sigma_beta, tau_beta, beta0,
  mu_theta, sigma_theta, theta0, data, t_insp, K, burnin
)
res_MLE <- mle(alpha0, beta0, theta0, data, t_insp)
plot4 <- vis_res(
  res_GMH, res_MLE, sim_og,
  subtitle = expression(alpha %~% "Gamma" ~ "et" ~ beta %~% "Uniforme")
)

# Visualisation finale
ggarrange(plot1, plot2, plot3, plot4, common.legend = TRUE)

```

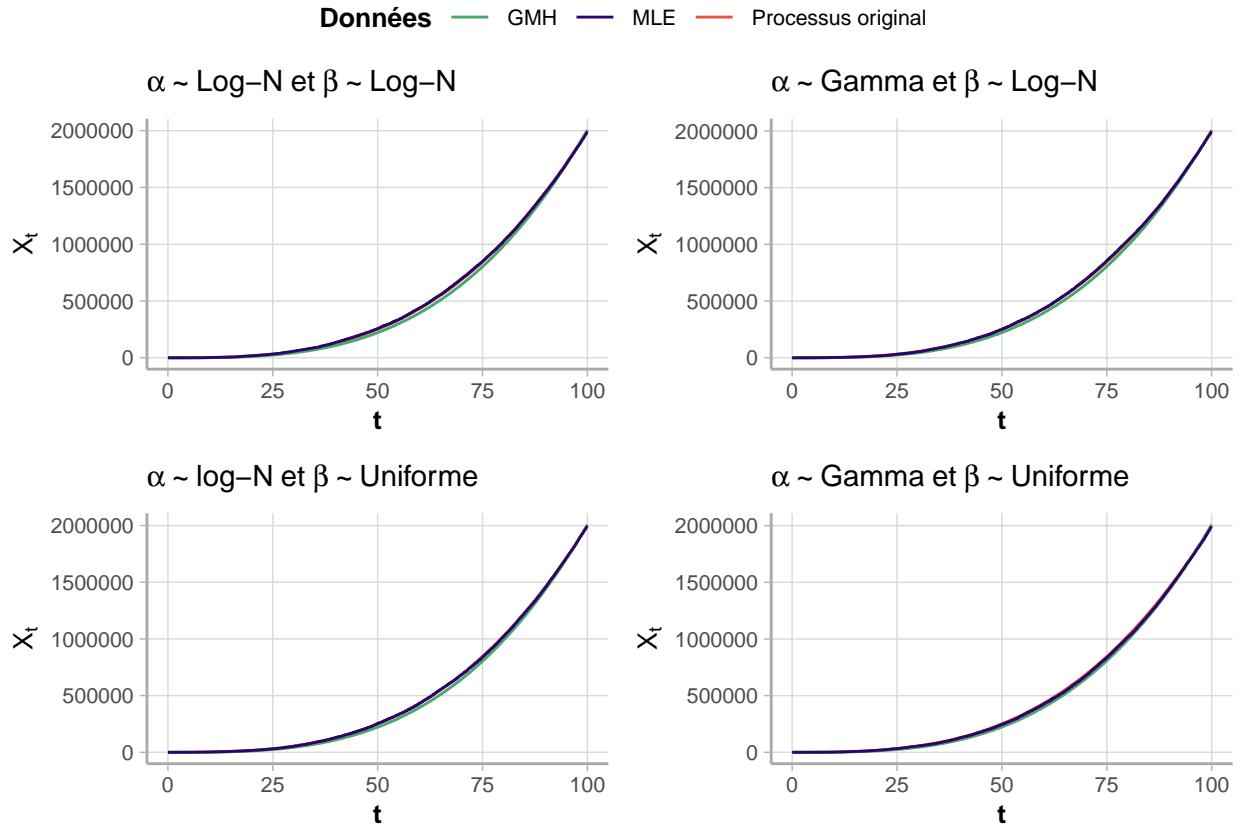


Figure 6: Résultats d'estimations bayésiennes et par maximum de vraisemblance lorsque $\beta > 1$

(6)

Commentaire : Il est important de vérifier la convergence de GMH et de MLE (GMH en faisant le plot de res_param et voir si bcp oscillations ou pas et pour MLE avec converged).

4 Conclusion